
Rapport de stage

*« Analyse des disparités Homme - Femme
en espérance de vie brute et en bonne santé »*

Réalisé par : Mohamed FOFANA

Formation : L3 MIASHS — Université Grenoble Alpes

Années Universitaire : 2025 - 2026

Sous la supervision de : M. Jacques DEMONGEOT

Enseignant référent : M. Julien GREPAT

Etablissement d'accueil : Laboratoire AGEIS

Durée : 28 Septembre 2025 - 10 Janvier 2026

Table des matières

1	Introduction	2
1.1	Présentation du laboratoire	2
1.2	Cadre conceptuel	2
2	État de l'art	3
2.1	Consolidation des compétences	3
2.2	Collecte et préparation des données	3
I	Analyse statistique et exploratoire des données	4
2.3	Analyse univariée	5
2.3.1	Distribution et Évolution temporelle des écarts moyens	5
2.3.2	Évolution des écarts moyens par sexe et selon le statut	5
2.3.3	Espérance de vie en mauvaise santé	7
2.4	Analyse bivariée	7
II	Approche économétrique : Données de panel et tests	9
2.5	Régression multiple	10
2.5.1	Données de panel	11
2.5.2	Tests statistiques	11
2.6	Résultats	11
3	Travail supplémentaire	12
3.1	Techniques d'apprentissage automatique	12
3.1.1	Apprentissage supervisé	12
3.1.2	Clustering	13
3.2	Résultats et limites	13
	Bibliographie	15

1.1 Présentation du laboratoire

Le laboratoire AGEIS (Autonomie, Gérontologie, E-santé, Imagerie et Société) est une unité de recherche pluridisciplinaire de l'Université Grenoble Alpes, fondée en 2015. Il étudie les problématiques liées à la santé, au vieillissement, à l'autonomie et aux inégalités sociales, en mobilisant des approches issues des sciences médicales, des sciences humaines et sociales et du numérique.

Ses travaux portent notamment sur la longévité, la qualité de vie, l'accessibilité aux soins et le développement d'outils numériques en santé, avec une attention particulière aux enjeux sociaux et éthiques. Le laboratoire bénéficie de collaborations nationales et internationales avec des institutions publiques, hospitalières et industrielles, notamment [Orange Labs](#), ainsi qu'avec le [CNRS](#) et l'[INSERM](#).

1.2 Cadre conceptuel

Les écarts d'espérance de vie entre femmes et hommes constituent un enjeu central en démographie et en santé publique. Si les femmes vivent en moyenne plus longtemps, cet avantage ne se traduit pas nécessairement par une meilleure santé.

Il convient de distinguer l'espérance de vie brute (**LE**), qui mesure le nombre moyen d'années vécues, de l'espérance de vie en bonne santé (**HALE**), qui intègre les années vécues avec des limitations de santé. Ces écarts résultent d'une combinaison de facteurs biologiques, comportementaux et structurels, incluant les inégalités sociales, le niveau de développement économique et l'organisation des systèmes de santé.

Mots clés

Espérance de vie ; Espérance de vie en bonne santé ; Espérance de vie ajustée sur l'incapacité ; Écart de longévité entre femmes et hommes ; Longévité liée au cancer

2.1 Consolidation des compétences

Ce stage a permis de consolider et d'approfondir des compétences méthodologiques, techniques et analytiques en statistique appliquée, économétrie et science des données, à partir de bases réelles, complexes et hétérogènes.

Sur le plan méthodologique, le travail a porté sur la collecte, le nettoyage et l'harmonisation de données internationales issues de sources multiples, en respectant des contraintes de cohérence temporelle et de comparabilité entre pays et sexes. L'utilisation conjointe de **R** et **Python** a permis de structurer les bases et de produire des analyses reproductibles, en mobilisant notamment **tidyverse**, **plm**, **pandas**, **numpy** et **matplotlib**.

En économétrie appliquée, le stage a impliqué l'estimation de régressions multiples et de modèles de données de panel. Les tests de Hausman, Wooldridge et Breusch–Pagan ont renforcé la capacité d'interprétation critique des résultats, en tenant compte des limites liées aux hypothèses des modèles.

Enfin, l'intégration de méthodes de Machine Learning supervisées et non supervisées (clustering, modèles prédictifs) a illustré la complémentarité entre approches statistiques classiques et outils modernes pour analyser les écarts Femmes–Hommes en santé et identifier des profils de pays distincts.

2.2 Collecte et préparation des données

Les données proviennent de la *banque mondiale*, de l'OMS, du PNUD et de l'IHME. Par souci de cohérence temporelle et de rigueur méthodologique, aucune extrapolation n'a été réalisée. L'analyse de ces données a donc été restreinte à l'année 2021. L'échantillon inclut des pays développés et en développement, permettant une analyse comparative selon le sexe, le temps et le niveau de développement. Après nettoyage et harmonisation, les données ont servi à deux analyses : une analyse exploratoire descriptive (EDA) et des modèles économétriques en données de panel. Les analyses, réalisées sous **R** et **Python**, sont documentées et les scripts sont disponibles sur GitHub : <https://github.com/Mohamed-Fof>.

Première partie

Analyse statistique et exploratoire des données

2.3 Analyse univariée

2.3.1 Distribution et Évolution temporelle des écarts moyens

Les distributions de la Figure 2.1 de LE_WMGap et $HALE_WMGap$ sont majoritairement positives, confirmant un avantage féminin généralisé. Elles présentent une asymétrie à droite, plus marquée pour l'espérance de vie brute. La distribution de $HALE_WMGap$ apparaît plus concentrée, suggérant des écarts de santé globalement plus limités que ceux observés pour la longévité.

L'évolution temporelle des écarts moyens LE_WMGap et $HALE_WMGap$ met en évidence une tendance générale à la réduction depuis les années 2000, avec une rupture marquée en 2020–2021, probablement liée à la pandémie de Covid-19 (Figure 2.2)




FIGURE 2.1 – Histogrammes des écarts F–H en espérance de vie brute et en bonne santé




FIGURE 2.2 – Évolution temporelle des écarts moyens Femmes–Hommes en espérance de vie brute et en bonne santé

2.3.2 Évolution des écarts moyens par sexe et selon le statut

Les distributions de LE et HALE par sexe montrent un décalage systématique en faveur des femmes, avec des valeurs globalement plus élevées. La dispersion indique toutefois que cet avantage moyen varie selon les pays (voir Figure 2.3).

Les écarts Femmes–Hommes diffèrent selon le niveau de développement : dans les pays développés, ils restent élevés mais tendent à diminuer, tandis que dans les pays en développement, les trajectoires sont plus hétérogènes, avec un impact marqué de la pandémie en 2020–2021 (voir Figure 2.4).




FIGURE 2.3 – Distribution de l'espérance de vie brute et de l'espérance de vie en bonne santé, par sexe




FIGURE 2.4 – Évolution moyenne des écarts Femmes–Hommes en LE et HALE selon le statut des pays

2.3.3 Espérance de vie en mauvaise santé

L'analyse de l'espérance de vie en mauvaise santé (différence entre LE et HALE) montre que les femmes vivent plus longtemps que les hommes, mais passent en moyenne davantage d'années en mauvaise santé. Ces écarts varient fortement selon les pays et doivent être interprétés avec prudence dans certains contextes, notamment lorsque les données reposent sur des estimations modélisées.





FIGURE 2.5 – Espérance de vie en mauvaise santé (LE – HALE) par sexe et par pays


2.4 Analyse bivariée

Des analyses bivariées ont été menées afin d'examiner les relations entre les écarts entre les deux sexes en espérance de vie (LE_WMGap) et en espérance de vie en bonne santé (HALE_WMGap), et plusieurs indicateurs socio-économiques et sanitaires, notamment le PIB par habitant, l'indice de développement humain (IDH) et les dépenses publiques de santé (DPGS).


Les graphiques de dispersion, complétés par des régressions linéaires et des lissages de type spline, mettent en évidence des associations statistiquement significatives pour l'IDH et les DPGS. Toutefois, ces résultats relèvent d'analyses descriptives et ne permettent pas d'inférer des relations causales, ce qui justifie le recours ultérieur à des modèles économétriques plus élaborés.




(a) PIB par habitant




(b) Indice de développement humain




(c) LE-DPGS (régression linéaire)



(d) LE-DPGS (spline)



(e) HALE-DPGS (régression linéaire)



(f) HALE-DPGS (spline)

FIGURE 2.6 – Relations entre l'écart Femmes–Hommes en (LE_WMGap & HALE_WMGap) et différents indicateurs socio-économiques et sanitaires, avec comparaison linéaire vs spline pour DPGS

Deuxième partie

Approche économétrique : Données de panel et tests

Cette partie présente la stratégie économétrique retenue pour analyser les déterminants de l'écart d'espérance de vie entre femmes et hommes, en espérance de vie brute (LE_WMGap) et en espérance de vie en bonne santé (HALE_WMGap). Elle décrit successivement l'approche par régression multiple, l'utilisation des données de panel, ainsi que les tests statistiques réalisés afin de vérifier la validité des hypothèses des modèles estimés.

2.5 Régression multiple

Dans un premier temps, une régression linéaire multiple, estimée par la méthode des moindres carrés ordinaires, est réalisée afin d'identifier les relations globales entre l'écart femmes-hommes et un ensemble de variables explicatives économiques, sanitaires et démographiques.

Les variables explicatives incluent l'indice de développement humain (IDH), le logarithme de l'indice de Gini, les dépenses de santé (part du PIB et part des dépenses publiques – DPGS), ainsi que la mortalité par cancers et VIH/SIDA.

Les résultats, présentés dans la Figure 2.7, indiquent que le modèle est globalement significatif (test de Fisher, p – value $< 2,2e - 16$) et explique une part substantielle de la variance de l'écart femmes-hommes (R^2 ajusté $\approx 0,68$). Plusieurs variables économiques et sanitaires apparaissent significativement associées à l'écart, notamment les inégalités de revenus, les dépenses de santé et certaines causes de mortalité, tandis que d'autres variables ne présentent pas d'effet statistiquement significatif.

Cette approche fournit une première lecture globale des relations étudiées. Toutefois, elle ne tient pas compte de l'hétérogénéité non observée entre pays ni de la dimension temporelle des données, ce qui motive le recours, dans la suite, aux modèles de données de panel.

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -8.766e+00  1.276e+00  -6.868 1.74e-11 ***
IDH           9.540e-01  8.166e-01   1.168 0.24317
log_Gini      2.721e+00  2.976e-01   9.143 < 2e-16 ***
Dep_sante_PIB -9.813e-02  3.032e-02  -3.237 0.00128 **
DPGS          1.176e-02  3.956e-03   2.972 0.00308 **
Cancer_thyroïde 6.114e-02  1.341e-02   4.560 6.28e-06 ***
Cancer_Estomac 3.919e-03  4.298e-04   9.118 < 2e-16 ***
Cancer_Utérus  3.929e-02  3.676e-03  10.690 < 2e-16 ***
Cancer_Foie    -1.669e-03  5.660e-04  -2.948 0.00333 **
Cancer_Sein    -1.265e-03  6.620e-04  -1.911 0.05651 .
Cancer_Testicule 6.329e-03  9.104e-03   0.695 0.48721
VIH_SIDA       5.711e-05  1.268e-05   4.505 8.09e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.207 on 560 degrees of freedom
Multiple R-squared:  0.688, Adjusted R-squared:  0.6819
F-statistic: 112.3 on 11 and 560 DF,  p-value: < 2.2e-16

```

FIGURE 2.7 – Résultats de la régression multiple

2.5.1 Données de panel

- Structure des données : Données de panel équilibrées avec des dimensions individuelles (pays) et temporelles (années).
- Méthodes de modélisation : Modèles à effets fixes et à effets aléatoires pour contrôler les effets spécifiques non observés des pays (voir Figure 2.8).
- Sélection du modèle : Le test de Hausman est utilisé pour déterminer si les effets fixes ou les effets aléatoires sont plus appropriés.

2.5.2 Tests statistiques

- Tests de spécification de modèle : Le test de Hausman est utilisé pour déterminer la spécification de panel la plus appropriée.
- Tests d'hypothèses classiques : Les tests de Wooldridge et Breusch-Pagan (et White) sont utilisés pour détecter l'autocorrélation sérielle et l'hétéroscédasticité, respectivement.
- Correction des erreurs standards : Des erreurs standards robustes, clusterisées au niveau des pays, sont utilisées pour obtenir des inférences statistiques plus fiables en présence d'autocorrélation et d'hétéroscédasticité.

2.6 Résultats

Cette section synthétise les résultats des régressions multiples et des modèles de panel appliqués aux écarts d'espérance de vie totale (LE_WMGap) et en bonne santé (HALE_WMGap). Les tests diagnostiques révèlent une autocorrélation et une hétéroscédasticité des résidus, justifiant le recours aux modèles à effets fixes, retenus via le test de Hausman, et à des erreurs standards robustes. Les estimations indiquent que certaines variables sanitaires, notamment le VIH/SIDA et certains cancers, conservent un effet significatif et robuste, tandis que plusieurs variables économiques perdent en significativité après correction. L'ensemble des résultats détaillés est présenté dans le fichier [Regression](#).

```

Coefficients:
      Estimate Std. Error t-value Pr(>|t|)
IDH          -1.1595e+00  7.1315e-01  -1.6258  0.104578
log_Gini      -8.5289e-01  3.6035e-01  -2.3669  0.018295 *
Dep_sante_PIB -7.5883e-02  2.3259e-02  -3.2625  0.001175 **
DPGS          1.5006e-02  3.7852e-03  3.9644  8.359e-05 ***
Cancer_thyroïde 8.2489e-02  9.9908e-03  8.2565  1.180e-15 ***
Cancer_Estomac 2.7449e-03  4.6154e-04  5.9472  4.928e-09 ***
Cancer_Utérus  -2.1894e-02  3.5822e-03  -6.1118  1.899e-09 ***
Cancer_Foie    -1.0425e-03  5.7793e-04  -1.8038  0.071829 .
Cancer_Sein    -1.8780e-03  6.1594e-04  -3.0491  0.002409 **
Cancer_Testicule 1.0574e-01  1.1751e-02  8.9979  < 2.2e-16 ***
VIH_SIDA      -1.0530e-04  8.7181e-06  -12.0785  < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    163.69
Residual Sum of Squares: 65.246
R-Squared:               0.60142
Adj. R-Squared:          0.5746
F-statistic: 73.3869 on 11 and 535 DF, p-value: < 2.22e-16

```

(a) Modèle à effets fixes pour LE_WMGap

```

Coefficients:
      Estimate Std. Error t-value Pr(>|t|)
IDH          -4.7326e+00  6.9480e-01  -6.8115  2.605e-11 ***
log_Gini      -7.9573e-02  3.5107e-01  -0.2267  0.820779
Dep_sante_PIB -7.9530e-03  2.2660e-02  -0.3510  0.725750
DPGS          9.6647e-03  3.6878e-03  2.6207  0.009023 **
Cancer_thyroïde 6.9895e-02  9.7337e-03  7.1808  2.333e-12 ***
Cancer_Estomac 2.2949e-03  4.4967e-04  5.1036  4.637e-07 ***
Cancer_Utérus  -2.6347e-02  3.4900e-03  -7.5493  1.899e-13 ***
Cancer_Foie    -4.8008e-04  5.6306e-04  -0.8526  0.394251
Cancer_Sein    5.4532e-04  6.0008e-04  0.9087  0.363895
Cancer_Testicule 9.5656e-02  1.1449e-02  8.3552  5.649e-16 ***
VIH_SIDA      -9.6751e-05  8.4937e-06  -11.3909  < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    162.28
Residual Sum of Squares: 61.93
R-Squared:               0.61837
Adj. R-Squared:          0.59269
F-statistic: 78.8065 on 11 and 535 DF, p-value: < 2.22e-16

```

(b) Modèle à effets fixes pour HALE_WMGap

FIGURE 2.8 – Méthodes de modélisation : Modèles à effets fixes

3.1 Techniques d'apprentissage automatique

Une approche de Machine Learning est utilisée pour l'analyse et la prédiction de l'écart d'espérance de vie Femmes–Hommes (LE_WMGap), à partir d'indicateurs sanitaires, socio-économiques et démographiques. L'étude porte sur 26 pays sur la période 2000–2021 et combine des méthodes supervisées et non supervisées afin d'identifier des déterminants clés et des profils homogènes de pays.

3.1.1 Apprentissage supervisé

Le problème est formulé comme une tâche de *régression*, la variable LE_WMGap étant continue. Une validation temporelle est mise en place, avec un apprentissage sur 2000–2017 et une évaluation sur 2018–2021, afin de tester la capacité de généralisation des modèles.

Les données sont prétraitées par *imputation médiane* et *standardisation*. Un modèle de *régression linéaire* est utilisé comme modèle de référence (*baseline*) pour sa simplicité et son interprétabilité. Les performances obtenues sont élevées ($R^2 > 0,9$), indiquant une forte capacité explicative de l'écart Femmes–Hommes (Figure 3.1).

Comparaison des modèles supervisés

Plusieurs modèles de Machine Learning ont été testés sur des données tabulaires (Ridge, ElasticNet, Random Forest, Gradient Boosting). L'évaluation utilise MAE, RMSE et R^2 .

Les modèles linéaires offrent les meilleures performances prédictives. Les modèles non linéaires plus complexes n'apportent pas d'amélioration notable et risquent le surapprentissage.

Sélection et validation du modèle

On choisit le modèle de régression linéaire pour son bon compromis entre performance et simplicité. La Figure 3.1 montre un bon ajustement, avec peu de dispersion autour de la diagonale.

On valide le modèle avec une séparation temporelle stricte des données, des métriques de régression et une analyse visuelle des prédictions (voir Tableau 3.1).

TABLE 3.1 – Comparaison des performances des modèles supervisés

Modèle	MAE	RMSE	R^2
Régression linéaire	0.406	0.516	0.924
Ridge	0.455	0.593	0.899
Gradient Boosting	0.445	0.609	0.894
ElasticNet	0.515	0.681	0.867
RandomForest	0.540	0.822	0.806

3.1.2 Clustering

En complément de la modélisation prédictive, une analyse de clustering a été menée afin d'identifier des profils homogènes de pays sur la base de leurs caractéristiques sanitaires et socio-économiques moyennes sur la période 2000–2021. Contrairement aux modèles supervisés, cette approche n'a pas pour objectif la prédiction, mais l'exploration des structures sous-jacentes dans les données.

Méthodologie

Les variables ont été agrégées au niveau pays à l'aide de la médiane, puis standardisées. L'algorithme des *k-means* a été appliqué pour différents nombres de clusters. Le choix du nombre optimal de clusters repose sur le score de silhouette, qui mesure la cohésion interne et la séparation entre groupes.

Résultats

Le score de silhouette maximal est obtenu pour $k = 2$, indiquant la structure de regroupement la plus cohérente. Deux profils distincts de pays émergent : un cluster regroupant des pays à profil sanitaire et socio-économique consolidé, et un second cluster caractérisé par une forte charge sanitaire et une vulnérabilité structurelle. La composante principale 1 fait apparaître 3 clusters : les pays africains et asiatiques en développement, les pays sud-américains et asiatiques à développement récent, et les pays européens et nord américains anciennement développés (Figure 3.2).

3.2 Résultats et limites

Cette étude mobilise des méthodes de Machine Learning supervisées et non supervisées pour analyser les déterminants de l'écart d'espérance de vie entre femmes et hommes. Les résultats montrent qu'un modèle de régression linéaire simple permet de prédire efficacement cet écart à partir d'indicateurs sanitaires et socio-économiques, tout en restant interprétable. L'analyse de clustering met en évidence des profils de pays distincts, caractérisés par des niveaux de développement sanitaire et des écarts `LE_WMGap` contrastés.

Plusieurs limites doivent toutefois être soulignées. L'analyse repose sur un nombre restreint de pays et une période relativement courte, ce qui limite la généralisation des résultats. Par ailleurs, certaines dimensions importantes, notamment institutionnelles, comportementales et environnementales, ne sont pas prises en compte. Leur intégration permettrait d'améliorer la capacité explicative des modèles.

Enfin, l'approche adoptée est essentiellement descriptive et prédictive. Le recours à des méthodes d'analyse causale, à des modèles dynamiques ou à des techniques de Machine Learning causal constituerait une extension pertinente de ce travail.

L'ensemble des analyses a été réalisé sous Python à l'aide de bibliothèques standards de science des données, dans une démarche reproductible. Le code est disponible sur GitHub (https://github.com/Mohamed-Fof/AGEIS_Stage_S5/tree/main/MachineLearning).




FIGURE 3.1 – Observé vs Prédit




FIGURE 3.2 – Visualisation cluster

Conclusion

Les écarts d'espérance de vie brute et en bonne santé entre femmes et hommes résultent de déterminants sanitaires, sociaux et structurels, certaines pathologies (VIH/SIDA, plusieurs cancers) jouant un rôle central.

Après correction des violations des hypothèses classiques des modèles linéaires, l'influence directe des variables économiques apparaît plus limitée, suggérant des effets principalement indirects via des mécanismes sanitaires ou institutionnels non observés. L'autocorrélation et l'hétéroscédasticité observées n'invalident pas les modèles, mais imposent une interprétation prudente des tests de significativité.

Les résultats révèlent la complexité des mécanismes expliquant ces écarts, qui ne se limitent pas à des facteurs économiques. Les pathologies spécifiques jouent un rôle central, tandis que l'influence des variables économiques est indirecte et médiée par des facteurs sanitaires, institutionnels ou comportementaux non observés. **Ces analyses descriptives et économétriques exploratoires mettent en évidence des associations et tendances sans permettre d'établir des relations causales.**

Ce stage a permis de consolider des compétences clés en analyse de données appliquée aux sciences sociales et à la santé publique, notamment en manipulation de données internationales, modélisation économétrique en données de panel, tests diagnostiques et méthodes de Machine Learning. Il a également renforcé les compétences en rédaction scientifique et en communication des résultats à l'aide de $\text{\LaTeX}$, R Markdown et Jupyter Notebook.

Bibliographie

Crimmins, E.M. (2025). Life Expectancy and Health Expectancy in the Twenty-first Century : The Unthinkable, the Inconceivable, and the Unknowable. *Demography*, 62, 1217–1236

Feraldi, A., & Zarulli, V. (2022). Patterns in age and cause of death contribution to the sex gap in life expectancy : A comparison among ten countries. *Genus*, 78, 23.

Worldlifeexpectancy (2025). <https://www.worldlifeexpectancy.com/>

Worldpopulationreview (2025). <https://worldpopulationreview.com/>

Perspective Monde (2025). Données démographiques mondiales, Université de Sherbrooke, 2025. <https://perspective.usherbrooke.ca>

World Bank (2024). World Development Indicators. <https://data.worldbank.org/>

WHO World Health Organization (2024). Global Health observatory (GHO) [data](#).

PNUD GLOBAL (2025) Human Development Index. [DataHDI](#)

Institut De Mesure Et D'évaluation De La Santé (2025). GBD Results. [Datacancers](#)

Duguet, E. (2011). Économétrie des panels. Université Paris-Est, [Pdf](#)

LeCointStat. (2023). *Guide Complet De La Regression Lineaire En Python - Machine Learning* [[YouTube](#)]

Machine Learnia. (2020). *Formation Python Machine Learning* [[YouTube](#)]

Trivial Physics. (2021). *Pourquoi les femmes vivent plus longtemps que les hommes ?* [[Youtube](#)]