

Analyse des Disparités Homme–Femme en Espérance de Vie Brute et en Bonne Santé

Auteur : Mohamed FOFANA

Formation : Stage S5 – L3 MIASHS
Université Grenoble Alpes

Lieu : Laboratoire AGEIS

Date : 19 janvier 2026



Contexte

- Les femmes vivent en moyenne plus longtemps que les hommes
- Mais cet avantage en longévité ne signifie pas toujours une meilleure santé
- Distinction de variables essentielles :
 - Espérance de vie brute (LE)
 - Espérance de vie en bonne santé (HALE)
 - Ecart d'espérance de vie brute H-F (LE_WMGap)
$$\text{LE_WMGap} = \text{LE_Femme} - \text{LE_Homme}$$
 - Ecart d'espérance de vie en bonne santé H-F
$$\text{HALE_WMGap} = \text{HALE_Femme} - \text{HALE_Homme}$$
- Enjeu majeur en démographie et santé publique

Problématique

Question centrale

Quels sont les déterminants sanitaires, économiques et sociaux des écarts d'espérance de vie entre femmes et hommes ?

- Rôle du niveau de développement
- Influence des dépenses de santé
- Impact des inégalités et pathologies spécifiques



Figure 1: Domaines

Objectifs du stage

- ➊ Analyser statistiquement les écarts entres les femmes et les hommes en espérance de vie brute (LE_WMGap) et en espérance de vie en bonne santé (HALE_WMGap)
- ➋ Identifier leurs déterminants via des modèles économétriques
- ➌ Explorer des approches complémentaires en Machine Learning

Données

- Sources internationales :
 - Banque mondiale
 - Organisation mondiale de la santé (OMS)
 - Programme des Nations Unies pour le Développement (PNUD)
 - Institute for Health Metrics and Evaluation (IHME)
- Période d'étude : 2000 – 2021
- 26 Pays dont: 13 Pays développés et 13 Pays en voie développement



Figure 2: Sources

Outils mobilisés

• Langages :

- R : analyse statistique et économétrie
- Python : data science et Machine Learning

• Méthodes :

- Analyse exploratoire des données (EDA)
- Régressions multiples
- Modèles de données de panel
- ML supervisé et non supervisé




Figure 3: R & Python






Figure 4: Pipeline data

Analyse univariée

- Avantage féminin généralisé en LE et HALE
- Distributions asymétriques
- Écarts (LE_WMGap) plus dense entre de 2 et 7
- Écarts (HALE_WMGap) plus dense entre de 0 et 5





Distribution de l'écart femmes-hommes moyen entre 2000 et 2021 pour 26 pays

Analyse exploratoire des données

Analyse univariée

- Les hommes vivent en bonne santé plus longtemps que les femmes au Maroc malgres que les femmes ont une esperance de vie plus que les hommes
- Écarts (LE_WMGap et HALE_WMGap) plus élevés en Russie
- Écarts HALE_WMGap plus faible en Inde, Iran, Nigeria




Histogramme de l'écart femmes-hommes moyen entre 2000 et 2021 pour 26 pays


Évolution temporelle

- Tendance générale à la réduction des écarts
- Rupture marquée sur la période 2020–2021
- Effet probable de la pandémie de Covid-19

Évolution de l'écart d'espérance de vie à la naissance (Femmes – Hommes) – Moyenne sur 26 pays



Évolution de l'écart HALE à la naissance (Femmes – Hommes) Moyenne sur 26 pays



Évolution de l'écart femmes-hommes moyen entre 2000 et 2021 pour 26 pays

Espérance de vie en mauvaise santé

Définition

Espérance de vie en mauvaise santé = LE - HALE

- Les femmes vivent plus longtemps, mais passent davantage d'années en mauvaise santé




Figure 5: Espérance de vie en mauvaise santé selon le sexe

Définition des variables


- **DPGS** : Domestic general government health expenditure – Dépenses publiques de santé du gouvernement, exprimées en pourcentage des dépenses de santé courantes totales.
- **PIB** : Produit Intérieur Brut par habitant (en \$US courants) – valeur totale de tous les biens et services produits par habitant dans un pays sur une période donnée.
- **IDH** : Indice de Développement Humain – mesure composite du niveau de développement humain incluant l'espérance de vie, l'éducation et le revenu par habitant.
- **Gini Index** : Indice de Gini – mesure des inégalités de revenu au sein d'un pays (0 = parfaite égalité, 1 = inégalité totale).

Relations bivariées


- Effets non linéaires pour certaines variables
- Différences d'intensité entre LE_WMGap et HALE_WMGap

Variable	LE_WMGap	HALE_WMGap
DPGS	+	+
IDH	+	+
Log(Gini)	+	+
PIB	+	-

Table : Signes pentes



Spline (LE vs DPGS)



Spline (HALE vs DPGS)

Régression multiple

- Modèle linéaire global
- Bon pouvoir explicatif (R^2 et R^2 ajusté ≈ 0.68)
- Variables sanitaires fortement significatives

Variable	Coef.	Std. err.	Sig.
Log(Gini)	2.721e+00	0.2976e-01	***
Cancer thyroïde	6.114e-02	1.341e-02	***
Cancer estomac	3.919e-03	4.298e-04	***
Cancer utérus	3.929e-02	3.676e-03	***
VIH / SIDA	5.711e-05	1.268e-05	***
Cancer du foie	-1.669e-03	5.660e-04	**
Dépense de santé	-9.813e-02	3.032e-02	**
DPGS	1.176e-02	3.956e-03	**
Significativités: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$			

Modèles de données de panel

- Comparaison entre modèles à effets fixes et effets aléatoires
- Sélection du modèle à l'aide du test de Hausman
- Utilisation d'erreurs standards robustes

Critère	Effets fixes	Effets aléatoires
Hétérogénéité pays	Oui	Oui
Corrélation avec X	Oui	Non
Test de Hausman	Rejet de H_0 (p-value < 0,01)	
Modèle retenu	Oui	Non
Autocorrélation	Oui (test de Wooldridge)	
Hétéroscédasticité	Oui (test de Breusch-Pagan)	
Erreurs standards robustes	Oui	Oui

Table : Synthèse des modèles de données de panel (LE_WMGap)

Variables ajoutées

Objectif

Améliorer la prédiction de l'écart d'espérance de vie et
Identifier des groupes de pays similaires en fonction des
variables socio-économiques, sanitaires et environnementales

- **Variables socio-démographiques et sanitaires :**
 - Chômage femmes / hommes
 - Mortalité infantile garçons / filles
 - Mortalité adultes femmes / hommes
 - Mortalité prématurée par maladies cardio-vasculaires femmes / hommes
- **Variables environnementales :**
 - Émissions de CO₂ par habitant

Apprentissage supervisé

- Tâche de régression
- Régression linéaire performante ($R^2 \approx 0.924$)
- Bon compromis performance / interprétabilité

Modèle	RMSE	R^2
Régression linéaire	0.516	0.924
Ridge	0.593	0.899
Gradient Boosting	0.609	0.894
ElasticNet	0.681	0.867
RandomForest	0.822	0.806

Table : Comparaison des performances des modèles supervisés

Clustering par ACP

- Identification de profils de pays
- Deux grands clusters principaux
- Différences sanitaires et socio-économiques marquées




Figure 6: Cluster par ACP

Matrice des contributions

- **PC1** : Niveau de développement économique et sanitaire
- **PC2** : Inégalités sociales et déséquilibres du marché du travail

Variables	PC1	Variables	PC2
IDH	0.303	Chômage_femmes	0.476
Mort_inf_garçons	-0.295	VIH / SIDA	0.374
Mort_inf_filles	-0.294	Gini	0.327
Mort_adultes_femmes	-0.281	Dep_sante_PIB	0.195
Mort_prem_femmes	-0.275	Mort_adultes_hommes	0.176
Mort_adultes_hommes	-0.263	Cancer_Sein	0.175
DPGS	0.257	CO_2 / habitant	0.171
PIB_habitant	0.255	Cancer_Utérus	0.144

Table : 8 Variables clés des axes PC1 et PC2


Conclusion

- Écarts F-H expliqués par des facteurs sanitaires majeurs
- Influence économique indirecte
- Importance des pathologies spécifiques

Limites et perspectives

- Nombre limité de pays
- Analyse non causale
- Perspectives :
 - Modèles causaux
 - Données plus riches
 - Approches dynamiques

Mind Mapping



Remerciements

Merci Pour Votre Attention !!!

- Des questions ou des commentaires ?